

## 박데이터의 개요 및 공공데이터를 이용한 데이터 분석

숭실대학교 베어드교양대학 서유화 교수 yhsuh@ssu.ac.kr 목차

- ▶ 빅데이터의 정의와 가치
- ▶ 빅데이터의 분류 및 분석 과정
- ▶ 공공데이터를 이용한 데이터 분석
  - ▶ 공공데이터 수집
  - ▶ 데이터 정제 및 탐색
  - ▶ 분석모델 구축 및 시각화

Soongsil University

## 오늘의 학습 목표

- ▶ 빅데이터의 정의와 기치를 설명할 수 있다.
- ▶ 빅데이터를 분류하여 설명할 수 있다.
- ▶ 공공데이터를 수집할 수 있다.
- ▶ 공공데이터로부터 질문을 찾아내고 필요한 요소를 발견할 수 있다.
- ▶ 시각화된 데이터로부터 새로운 인사이트를 발견할 수 있다.
- ▶ 데이터분석 과정을 이해하고 설명할 수 있다.

## 지난시간 배운 내용

주	주제	온라인	오프라인	
1	인공지능의 과거 현재와 미래	1. 강의 및 교과목 소개(공통, 핵심만) 2. 인공지능의 과거와 현재 3. 인공지능의 미래와 다양한 시선 4. 인공지능 개발환경 구축과 사용법(Anaconda/Colab)	1. 강의 및 교과목 소개(분반별 자세히) 2. 다양한 인공지능 기술 경험하기 (자연어처리, 시각, 음성) 3. 인공지능 챗봇만들기(IBM 왓슨 어시스턴트)	
2	공공데이터를 이용한 사회문제 발견과 해결책 모색	1. 빅데이터의 정의와 가치 2. 공공데이터 수집하기 3. 공공데이터로부터 새로운 인사이트 발견하기 - 행정구역별 인구 데이터와 공공의료기관 현황 데이터 분석	1. 서울시 CCTV설치 현황 분석하기 2. 서울시 범죄발생 현황 분석하기	
3	인공지능의 개요 및 머신러닝을 이용한 예측	1. 인공지능의 정의와 분류 2. 인공지능 학습방법 이해하기 3. 인공지능 알고리즘 소개	1. 머신러닝을 이용한 이미지 식별(구글 티쳐블 머신) 2. 머신러닝을 이용한 보스톤 집값 예측	
4	인공지능과 데이터 윤리	1. 데이터의 불완전성과 결함에 따른 예측 오류와 차별 2. 데이터 왜곡에 따른 분석과 예측 결과 비교	<ol> <li>데이터 편향성이 예측에 미치는 영향 (구글 티쳐블 머신)</li> <li>데이터 왜곡에 따른 예측 결과 비교</li> <li>타이타닉호 생존자 예측</li> </ol>	
5	인공지능과 알고리즘 윤리	1. 알고리즘 기반 의사결정 시스템의 한계 2. 윤리가 적용된 인공지능 알고리즘	1. 알고리즘에 따른 예측 결과 비교 - 보스톤 집값 예측 - 폐암환자 생존 여부 예측	
6	인공지능에 대한 다양한 이슈와 우리의 자세 고찰	1. 인공지능의 윤리적/법적 쟁점 (자율주행자동차, AI로봇, 트랜스 휴먼 등) 2. 인공지능시대 사회, 경제적 불평등 문제 3. 인공지능과 프라이버시 4. 인공지능의 윤리적 대응과 규제	1. 자율주향 자동차의 행동학습 시나리오 경험하기 2. 비윤리적 데이터 생성과 수집(웹 크롤링을 이용한 데이터 수집)	
7		기말고사		

Soongsil University

Soongsil University



## 빅데이터의 개요

## 빅데이터 정의

기관 정의 일반적이 데이터베이스 소프트웨어가 수집, 저장, 관리, 분석할 수 있는 범위를 초과하 맥킨지 (Mckinsey) 는 대규모의 데이터 향상된 시사점과 더 나온 의사결정을 위해 사용되는 것으로 비용 효율이 높고 혁신적이 기트너(Gartner) 며 대용량 고속 및 다양성을 가지는 정보 자산 기존 데이터 베이스 관리도구의 수집, 저장, 관리, 분석 역량을 넘어서는 대량의 정형 또 이피미미타 는 비정형 데이터 셋 및 이러한 데이터로부터 가치를 추출하고 결과를 분석하는 기술 저장, 관리, 분석할 수 있는 범위를 초과하는 규모의 데이터와 이것을 저장, 관리, 분석 할 수 있는 하드웨어 및 소프트웨어 기술, 데이터를 유통 및 활용하는 과정을 통틀어 나 한국정보회진홍원 타냄. 즉 빅데이터를 구성하는 하드웨어, 소프트웨어 그리고 이를 포괄하는 모든 프로세 스를 의미하는 거대 플랫폼

Soongsil University

## 빅데이터의 가치

▶ 맥킨지가 제시한 빅데이터가 가치를 만들어내는 방식

정보의 투명성	• 이해 관계자가 적시에 쉽게 빅데이터에 접근가능하여 연구개발 및 관리 효율성 제고
시뮬레이션을 통한 수요 발견,	• 더 많은 거래 데이터를 디지털 형식으로 축적함에 따라 정확하고 상
트랜드 예측, 성과 관리	세하게 소비자 요구를 발견하거나 트랜드 예측
소비자 맞춤 비즈니스를 위한	• 빅데이터를 통해 더 구체적으로 고객을 세분한하여 고객의 요구에
고객 세분화	맞는 더 정확한 맞춤형 서비스 제공
자동화된 알고리즘을 통한 의사결정	• 전체 데이터셋을 정교하게 분석함으로써 의사결정을 개선하고 위험을 최소화할 수 있으며 가치 있는 인사이트를 발굴
새로운 비즈니스 모델, 상품	• 새로운 상품 및 서비스를 개발하거나 기존 상품 및 서비스를 강화하
서비스의 혁신	역 완전히 새로운 비즈니스 모델 개발

Soongsil University

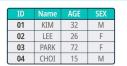
## **빅데이터의 분류**

- ▶ 정형데이터(structured data)
  - ▶ 미리 정해 놓은 형식과 구조에 따라 저장된 데이터
    - ▶ 예) 관계형 데이터베이스의 테이블, 스프레드시트, CSV 등
- ▶ 반정형데이터(semi-structured data)
  - ▶ 일정한 규칙의 고정된 필드에 저장되어 있지 않지만 데이터 의 구조 정보를 데이터와 함께 제공하는 파일형식 데이터
    - ▶ 예)XML, HTML, JSON, 웹문서, 웹로그 등

#### ▶ 비정형데이터(unstructured data)

- ▶ 정의된 구조가 없이 데이터지체만으로 내용에 대한 질의 처 리를 할 수 없는 데이터
  - ▶ 소셜 데이터, 텍스트 문서, 동영상/이미지/음성 데이터, 문서 (PDF) 등

[이미지 출처]: 정보통신용어사전 (http://terms.tta.or.kr/dictionary/dictionaryView.do?word\_seq=175128-2)



structured data



semistructured data



unstructured



Soongsil University

## 빅데이터 분석의 과정

- 무엇을?
- 어디 사용?
- 어떤 데이터?
- 데이터 유형과 종류에 따라 맞는 수집 기술 사용
- 데이터 여**과** 정제,통합,축소, 변환
- 데이터 변수간 관계 및 상호작용, 분포 등을 탐색
- 통계분석모델 • 머신러닝/티러닝

변수를 선택하여

모델을 구성 및

Soongsil University

## 공공데이터를 이용한 데이터 분석

> 행정구역별 의료기관 현황 분석하기

## 행정구역별 의료기관 현황 분석하기

▶목표

▶ 행정구역별로 공공보건의료기관 수를 파악하고 인구 수 대비 공공의료기관 비율을 비교 분석한다.

▶ 데이터 수집

1. 국가통계포털: 행정구역\_시군구\_별\_\_성별\_인구수.xlsx

2. 공공데이터포털: 공공보건의료기관현황.csv

▶ 데이터 정제와 탐색

- 1. 데이터 읽어와 행정구역 분리하기
- 2. 행정구역 이름으로 주소 수정
- 3. 행정구역별 공공보건의료기관 수 집계
- 4. 행정구역별 인구수 데이터 정리
- 5. 테이블에 필요한 컬럼 추출 후 테이블 병합

▶ 분석모델 구축 및 시각화



공공데이터 수집

Soongsil University

15

## 공공데이터 수집

### ▶ 공공데이터 제공 사이트

시	설명
https://www.data.go.kr	한국 정부에서 제공하는 공공데이터(공공데이터포털)
https://kostat.go.kr	통계청에서 공개하는 데이터
https://opendata.hira.or.kr	한국 보건 의료 빅데이터 개방 시스템
https://www.localdata.kr	한국 지방 행정 인허가 데이터
https://www.mcst.go.kr	한국문화체육관광부 문화 데이터
https://data.seoul.go.kr/	서울 열린데이터 광장
https://data.gg.go.kr	경기도 공공데이터 개발 포털
https://www.data.gov/	미국 정부의 공공데이터
https://data.worldbank.org/	세계 은행에서 제공하는 개방 데이터
https://open.fda.gov/	미국 식약청의 개방 데이터

Soongsil University

## 1. 행정구역 주소 체계 데이터 수집

▶ 국가중계포털 ^t이트 <u>https://kosis.kr</u>



## 1. 행정구역 주소 체계 데이터 수집

① 창이 뜨고 시/도만 있고 군/구 데이터가 보이지 않음





# 1. 행정구역 주소 체계 데이터 수집







▶ 궁궁데이터 포털 : https://www.data.go.kr/



## 2. 전국 공공보건의료기관 데이터 수집

1. 행정구역 주소 체계 데이터 수집

4.916.548

62,997

117,430

170,705

60,019

108.948

167, 335

행정구역(시군구)별, 성별 민구수

서울특별시

성동구 동대문구

중랑구

제공기관

관리부서명

보유근거

수집방법

관리부서 전화

보건복지부

정보화담당관

044-202-3707

업데이트 주기 수시 (1회성 데이터)

총인구수 (명)

338,040

302,645 추정치, p: 잠정치, -: 자료없음, ... : 미상자료, x: 비밀보호, ▽: 시계열 불연속

오류신고 및 담당자 문의 csv 보건복지부\_공공보건 의료기관 현황 ※ 다운로드 및 활용신청은 PC버전에서만 가능합니다. 다운로드 보건복지부\_공공보건 의료기관 현황\_20161231 보건 - 보건의료

3. 다운로드한 파일 이동

▶ 다운로드한 2개의 파일 (윈도우 탐색기 -> 다운로드 폴더)

▶ 주피터노트북에서 데이터를 사용시 소스코드(노트파일 .ipynb)와 같은 위치 로 이동 시켜야 함

▶ 예) C → ^i용자 → ^i용자계정 → data (새 폴더 생성) → 다운로드한 2개 파일 이동



2. 전국 공공보건의료기관 데이터 수집

다운로드 ☑ 빈셀 부호(-) □ 통계부호 □ 코드포함 ○®csv ② EXCEI 선택 □ 주석정보 □ 주소정보 □ 행렬전환 圖분석 ② 차트 ◎ 부가기능설정 ☆ 스크라 □ □ 다운로드 □ 인쇄 □ 도움말 ○ SDMX(2.0) [ ○ DSD (데이터구조) ○DATA Generic 1 ○ 모름차순 ○ 내림차순 ○ 수록자료형식과 동일 ⑥ 조회화면과 동일

통계설명자료 온라인간행물

① 다운로드 클릭

☞선택한 시점의 계열(항목×분류)에 자료가 없을 때는 표시되지 않습니

Soongsil University

Soongsil University

마운로드 3 디온로드

## 4. 데이터 준비하기

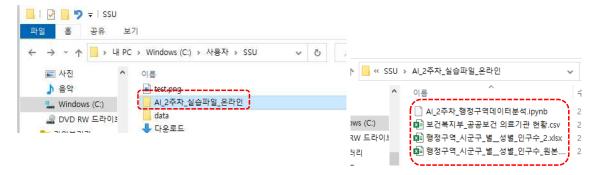
- 1) 다운로드한 '행정구역\_시군구\_별\_\_성별\_인구수.xlsx' 파일 열기
- 2) 1레벨 시와 2레벨(군/구)가 같은 열에 있음으로 분리
  - 1) 새열을 생성하여 1레벨과 2레벨을 분리하고 아래와 같이 빈자리에 소계 추가
  - 2) 파일명 아래와 같이 변경

	A	В	С	D	E	
- 1	행정구역(시군구)별(	행정구역(시군구)별(	총인구수 (명)	남자인구수 (명)	여자인구수	☑
2	전국	소계	51,847,509	25,862,863	25,98	파일 홈 공유 보기
3	서울특별시	소계	9,733,509	4,745,088	4,98	← → · ↑  « Windows (C:) › 사용자 › SSU › data
1	서울특별시	종로구	151,215	73,688	7	- A Thindon's (c.) 7 148-17 555 7 data
5	서울특별시	중구	126,201	61,946	E	∰ 문서 <mark>^</mark> 이름
3	서울특별시	용산구	229,385	110,701	11	█ 바탕 화면 ☑ 보건복지부_공공보건 의료기관 현황.csv
7	서울특별시	성동구	300,410	147,020	15	■ 사진 ■ 행정구역_시군구_별_성별_인구수_2.xlsx
3	서울특별시	광진구	351,263	170,164	18	) 음악 회정구역_시군구_별_성별_인구수_20210730155709.xlsx
)	서울특별시	동대문구	346,080	171,964	17	Windows (C:)
0	서울특별시	중랑구	396,755	196,803	199,	,952

Soongsil University

## 5. 소스코드 예제 파일 열기(아나콘다)

- ① 스마트 캠퍼스 2주차 실습파일 압축파일 다운 후 압축풀기
  - ▶ 앞장의 데이터 준비과정을 미리 수행해 놓은 파일이 업로드 되어있음
- ② 압축푼 폴더는 C:\사용자\사용자명 폴더 이래 가져오기



Soongsil University

## 5. 소스코드 에제 파일 열기(아나콘다)

▶ 주피터노트북 실행 후 예제 파일 열기





Soongsil University

## 5. 소스코드 예제 파일 열기(Colab)

- ① 스마트 캠퍼스 2주차 실습파일 압축파일 다운 후 압축풀기
  - ▶ 앞장의 데이터 준비과정을 미리 수행해 놓은 파일이 업로드 되어있음
- ② Colab 실행 후 구글드라이브 폴더에 새폴더 생성 후 해당 파일 업로드



24

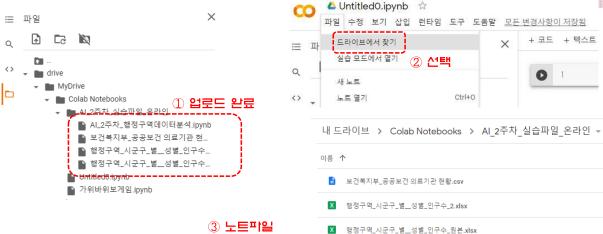
## 5. 소스코드 예제 파일 열기(Colab)

- ① 스마트 캠퍼스 2주차 실습파일 압축파일 다운 후 압축풀기
  - ▶ 앞장의 데이터 준비과정을 미리 수행해 놓은 파일이 업로드 되어있음
- ② Colab 실행 후 구글드라이브 폴더 이래로 해당 폴더 업로드



5. 소스코드 예제 파일 열기(Colab)

25



③ 노트"일 더블클릭하여 열기

■ AI\_2주차\_행정구역데이터분석.ipynb